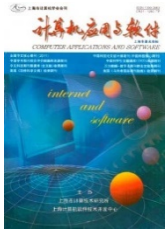

计算机应用与软件
Computer Applications and Software
ISSN 1000-386X,CN 31-1260/TP

《计算机应用与软件》网络首发论文

题目：　融合 LLM 的自然语言驱动自动驾驶极端仿真场景生成
作者：　张雨丹，周庆辉，孙舜杰，王金海
收稿日期：　2025-10-29
网络首发日期：　2026-02-14
引用格式：　张雨丹，周庆辉，孙舜杰，王金海．融合 LLM 的自然语言驱动自动驾驶极端仿真场景生成[J/OL]．计算机应用与软件．
https://link.cnki.net/urlid/31.1260.TP.20260214.1414.002

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-02-14 15:16:26　网络首发地址：https://link.cnki.net/urlid/31.1260.TP.20260214.1414.002

融合 LLM 的自然语言驱动自动驾驶极端仿真场景生成

张雨丹　周庆辉*　孙舜杰　王金海
（北京建筑大学机电与车辆工程学院　北京 102616）

摘　要　场景多样性与高危交通事件复现能力是衡量自动驾驶仿真平台实用性与安全覆盖率的重要指标。该研究针对自动驾驶仿真测试中场景构建耗时长、极端场景覆盖不足的问题，提出一种融合大语言模型（LLM）的自然语言驱动自动驾驶仿真场景生成方法，该方法以自然语言描述为输入，经 LLM 语义解析生成结构化交通场景 JSON，通过脚本自动生成模块转化为 CARLA 可执行脚本，实现从语言输入到仿真执行的端到端自动闭环。系统设计了多角色行为控制函数库与六视角图像同步采集机制，支持多车交互、异常行为复现与多模态数据自动采集。实验结果表明，所提方法在构建语义一致、高危交互、自动执行的仿真场景方面表现出良好的生成能力，并在数据多样性与极端性方面有效补充了真实道路数据集。

关键词　大语言模型（LLM）　自动驾驶仿真　场景生成　CARLA 仿真平台

中图分类号　TP311　　**文献标志码**　A

NATURAL LANGUAGE-DRIVEN EXTREME SCENARIO GENERATION FOR AUTONOMOUS DRIVING WITH LARGE LANGUAGE MODELS

Zhang Yudan　Zhou Qinghui*　Sun Shunjie　Wang Jinhai
(*School of Electromechanical and Vehicle Engineering, Beijing University of Civil Engineering and Architecture, Beijing 102616, China*)

Abstract　Scene diversity and the ability to reproduce high-risk traffic events are crucial indicators for evaluating the practicality and safety coverage of autonomous driving simulation platforms. To address the challenges of time-consuming scenario construction and insufficient coverage of extreme edge cases in autonomous driving simulation testing, this study proposes a natural language-driven scenario generation method for autonomous driving that integrates large language models (LLMs). The proposed framework takes natural language descriptions as input and employs the LLM for semantic parsing to generate structured traffic scene representations in JSON format. These are subsequently converted into executable Python scripts for the CARLA simulator through an automatic script generation module, achieving an end-to-end closed loop from language input to simulation execution. Furthermore, a multi-agent behavior control function library and a six-view synchronized image acquisition mechanism are designed to support multi-vehicle interaction, abnormal behavior reproduction, and automated multimodal data collection. Experimental results demonstrate that the proposed method exhibits strong capabilities in generating semantically consistent, high-risk interactive, and automatically executable simulation scenarios, effectively enhancing the diversity and extremity of datasets and complementing real-world road data for autonomous driving validation.

Keywords　Large language model (LLM)　Autonomous driving simulation　Scenario generation　CARLA simulation platform

0　引　言

自动驾驶系统的安全性在很大程度上依赖于对多样化交通场景的充分测试，尤其是涉及稀有与高风险情境的验证。然而，单纯依靠真实道路行驶数据收集此类场景不仅成本高昂，而且难以覆盖所有潜在的极端情况。因此，在仿真环境中开展基于场景的测试已成为评估和验证自动驾驶系统安全性与性能的关键途径[1]。作为物理道路测试的一种经济高效替代方案，仿真测试能够构建逼真、可重复且可控的驾驶环境[2]，并在重现安全关键情境方面具有显著优势，特别是那些在真实数据集中罕见或难以捕获的极端场景[3,4]。因此，系统化生成与分析安全关键驾驶场景被视为支持基于场景测试的核心机制，并已成为推动自动驾驶功

收稿日期：2025-10-29。北京市自然科学基金项目（L231016）；北京市教育科学“十四五”规划课题（CDDB23219）。**张雨丹**，硕士生，主研领域：车辆轨迹预测。**周庆辉**，教授。**孙舜杰**，硕士。**王金海**，副教授。

能开发、验证与确认的重要基础[5]。

近年来，场景生成研究涌现出多种研究方法，主要分为基于数据驱动的方法和基于大语言模型（LLM）的方法。基于数据驱动的方法主要依赖大规模真实交通数据集，通过建模其潜在分布与规律，利用生成模型实现场景的构建。Sun 等人[6]建立 Drivescenegen 模型，通过学习真实世界驾驶数据集以生成动态驾驶场景；Feng 等人[7]使用图结构深度学习建模生成结构化、丰富的交通场景，旨在提高多样性与真实感；Tan 等人[8]利用神经自回归模型，在给定高精地图基础上添加道路参与者，提高场景生成的逼真度；Zhou 等人[9]利用扩散模型，通过逆向去噪过程从白噪声合成道路布局，从而保留现实世界的空间特征；Li 等人[10]提出的仿真平台支持从大规模数据集中抽取真实场景并进行交互复现与复杂场景构造。这类方法在分布逼真度与统计代表性方面具有优势，但其生成能力受到原始数据覆盖范围的严格限制，对真实数据中本就稀缺的极端场景往往难以充分建模；同时，其场景控制粒度主要停留在轨迹与布局层面，缺乏对高层语义意图与事故机理的显式表达与可控编辑。

随着大语言模型和多模态基模型的发展，其在自动驾驶场景编码与生成中的潜能被广泛探索与应用。Tang 等人[11]使用 LLM 将自然语言描述的“功能场景”逐步转换为逻辑场景，实现从抽象到具体的场景生成结构控制；Ruan 等人[12]提出 Text-to-Traffic Scene 框架，利用 LLM 在 CARLA 仿真环境中生成多样化、可控的交通场景，实现从无特定轨迹到完整场景的构建，减少碰撞概率；Miceli-Barone 等人[13]使用对话式交互让用户通过自然语言一步步细化场景生成，LLM 将用户指令即时转换为可执行的领域专用代码，增强场景的交互可控性；Cai 等人[14]通过精心设计的提示（Prompt），从文本输入中解析并构建出可执行的测试场景，基于语料库中的结构化场景组件进行组合生成。Chang 等人[15]提出的场景生成模型包括场景 Prompt 工程、LLM 场景生成与评估反馈调优，系统地研究了如何通过 LLM 自动构建交通场景。LLM 驱动方法能够在语义层面进行场景建模，擅长处理多主体、多事件的复杂语言描述，并通过结构化输出接口与下游模块对接，弥补了传统数据驱动方法在语义可解释性和人工可控性方面的不足。

然而，现有 LLM 驱动场景生成方法仍存在局限，一是多数工作仅实现了文本到代码片段的转换，仍需要人工对接仿真平台，未形成真正意义上的从自然语言输入到仿真执行的端到端闭环；二是对物理可行性与事故机理的一致性约束较弱，缺乏基于动力学模型与碰撞条件的显式约束机制，容易出现语义合理但物理上难以复现的场景；三是现有方法多侧重于方法演示和场景构造，较少将生成结果系统整理为可复用的仿真数据集，对感知、预测等下游任务在极端场景上的数据补充作用仍然有限。

因此，有必要构建一种兼具语义可控性、物理一致性与仿真可执行性的 LLM 驱动场景生成方法，使自然语言描述既能够被解析为标准化场景表示，又能够自动映射到仿真平台中执行并同步输出多模态数据，从而形成可复用的极端场景数据集。本研究提出一种融合 LLM 的自然语言驱动自动驾驶极端仿真场景生成方法，以端到端闭环架构和极端场景构造机制为切入点，增强长尾场景的生成能力与覆盖度。本研究的主要工作如下：

（1）端到端闭环场景生成流程：构建面向极端交通场景的自然语言驱动闭环框架，实现从自然语言输入、脚本自动生成、仿真执行结构化场景生成到多模态数据输出的全过程自动化。

（2）多角色行为控制与调度：设计自动加载与行为调度模块，构建面向自然语言的模块化交通参与者函数库，将高层语义动作抽象为可复用的中层行为模板。系统根据语义自动调用并组合多类型交通行为集成至 CARLA 仿真脚本中，实现复杂交互事件的自动复现与灵活扩展。

（3）多模态仿真数据采集与可视化：集成六视角摄像头同步采集机制，实现主车多角度图像、碰撞事件与轨迹信息的自动采集与存储，通过可视化界面呈现仿真过程，为交通行为分析与验证提供数据支持。

（4）极端交通场景生成与数据集补充：面向长尾交通事件，通过语义解析、参数设定和约束筛选主动生成包含多车交互、恶劣天气和异常行为的高危场景集，有效弥补真实道路数据在极端场景和复杂交互方面的不足，提升自动驾驶模型的鲁棒性和泛化能力。

1 场景生成模型构建方法

1.1 系统整体架构

本研究提出的融合 LLM 的自然语言驱动自动驾驶极端仿真场景生成系统整体架构如图 1 所示，主要包括三个核心模块：基于 LLM 的自然语言解析模块、脚本生成器模块和 CARLA 仿真执行模块，共同构成从语言输入到仿真运行的闭环自动场景生成流程。

首先，用户输入包含交通事件描述的自然语言文本，该文本可描述天气、道路类型、参与者类型、行为特征以及潜在事件，如碰撞、避让等，基于 LLM 的自然语言解析模块将用户输入的自然语言文本送入

deepseek[16]中进行语义转换。模型基于预定义的语义格式对输入语句进行结构化提取，输出包含场景组成要素的标准化 JSON 文件，涵盖天气条件、道路类型、交通参与者属性、行为模式以及预期的事件类型与原因等信息。随后，结构化 JSON 作为语义中间层输入到脚本生成器模块，该模块将各语义要素转译为 CARLA 模拟平台可识别并执行的控制脚本，完成场景中对象实体的生成、环境配置、初始位置设定以及行为逻辑控制。在仿真阶段，生成的脚本被自动加载至 CARLA 模拟平台中运行，仿真模块根据设定执行各交通行为并生成完整的动态场景。本系统集成的六个视角的相机传感器与 nuScenes 数据集[17]进行道路数据采集的摄像机视角相同，分别从车辆正前方、左前方、右前方、正后方、左后方、右后方六个方位采集图像数据，实现多视角同步感知，并且系统自动采集仿真运行过程中的车辆轨迹、周围环境图像、碰撞瞬间等多模态信息。

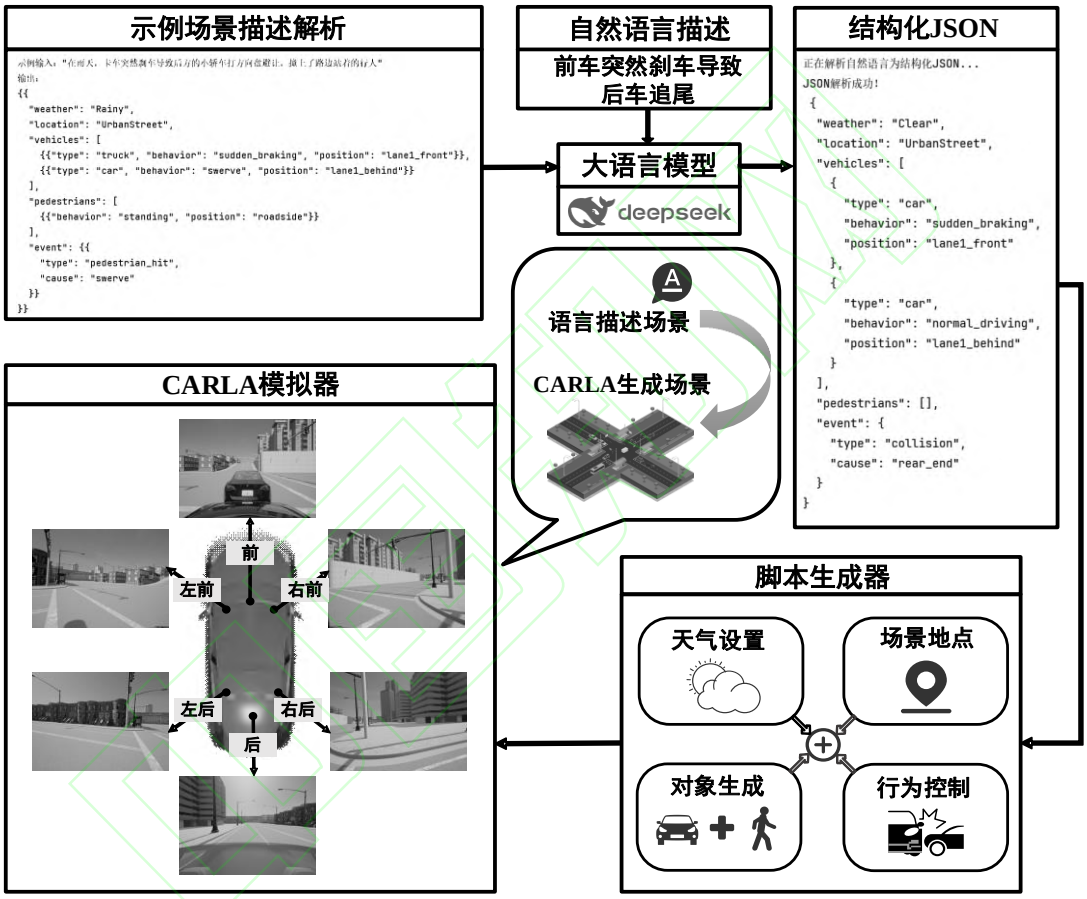

图 1 场景生成模型整体架构

1.2 基于 LLM 的自然语言解析模块

基于 LLM 的自然语言解析模块负责将用户输入的无规则自然语言描述转换为规范化文本格式，并构建适配大语言模型的高质量 Prompt 示例，为后续语义结构提取提供标准化输入。为避免语义解析过程仅停留在模板匹配和字段抽取层面，本研究在 Deepseek 模型中采用推理导向的解析流程。模型首先利用链式思考将输入文本划分为环境、交通参与者、行为动作和事件结果等关键要素，在此基础上推断各要素之间的因果关系和场景结构。对于模糊或主观表达，系统结合预设参数范围和交通物理约束，将其转化为带有上下界的量化参数，生成在语义上合理且物理上可行的场景候选。通过这种基于推理与约束相结合的机制，Deepseek 在处理歧义、缺省和口语化表达时，能够输出更加稳定、可解释的结构化场景表示。

1.2.1 输入格式定义

本系统允许用户以非结构化的自由文本形式输入交通事件描述，该输入可来自于普通用户的口语化表达、自动驾驶测试工程师的测试需求描述，或事故分析文档中的定性叙述，不局限于固定的语法风格与表达模板。例如，系统可接受如下类型的输入："在雨天，前车急刹车，后车来不及反应撞了上去"、"城市交叉口处，行人闯红灯被小车撞到"。

自然语言的输入以人为语言习惯表述场景内容，主要包括以下四类核心信息：环境要素、参与者信息、

行为动作、事件结果。具体信息见表 1。

表 1 语义要素与语义示例对照表

语义要素		语义实例
环境要素	天气	晴天、雨天、多云、雾天、沙尘暴、雪天、冰雹等
	道路	城市道路、高速公路
交通参与者	车辆	小汽车、卡车、公交车、自行车、摩托车
	行人	小孩、年轻人、老人
行为动作	针对车辆	正常行驶、刹车、闯红灯、换道、打滑等
	针对行人	正常行走、闯红灯、静止等
事件结果		多车碰撞、追尾、撞到行人等

1.2.2 预处理策略与词表标准化

在自动驾驶场景建模与安全测试中，往往需要通过受控词表和场景本体，将自然语言描述统一映射为标准化的场景要素和标签，这有助于提高场景描述的一致性与机器可读性[18,19]。文本归一化和词汇标准化也是提高下游模型稳定性和鲁棒性的经典预处理步骤，已在语音合成、识别等任务中得到系统研究和验证[20,21]。本研究根据交通场景相关语料构建车辆行为、行人行为归一词典映射表及方位词映射表，见表 2 至表 4，语料来源包括自动驾驶测试用例及公开数据集附带的场景描述[18]。在输入层对多样化、口语化的表达进行规范化处理，统一映射为有限的受控标签集合，从而缩小 LLM 需覆盖的表达空间，降低语义解析结果随机性，提高结构化 JSON 输出的一致性与可解释性。

表 2 车辆行为归一词典映射表

原始自然语言表达	归一化行为标签（标准 JSON 字段）	语义说明
猛踩刹车、急刹车、紧急制动	sudden_braking	表示车辆在短时间内快速减速或完全制动
停车、停在原地、不动了	stopped	表示车辆处于静止状态
撞车、发生碰撞、追尾了	collision	表示与其他交通参与者发生碰撞
闯红灯、冲过信号灯	running_red_light	表示无视信号灯控制进入交叉口
避让、打方向盘、躲闪	swerve	表示驾驶员通过急转向改变行驶方向
打滑、失控、滑行、路滑	skidding	表示车辆因失去抓地力而非控制性运动
正常行驶、匀速开车、正常驾驶	normal_driving	表示车辆处于无异常状态下的正常行驶
改道、换车道、并线	lane_change	表示车辆在同向车道间进行变道操作

表 3 行人行为归一词典映射表

原始自然语言表达	归一化行为标签（标准 JSON 字段）	语义说明
过马路、穿马路、行人过街	crossing	行人正处于横穿道路或人行横道的动作中
行走、慢慢走、在人行道上走	walking	行人以正常速度行进
跑、奔跑、飞奔	running	行人以较快速度运动，可能为躲避等情形
站立、停下不动、等红灯	standing	行人静止未动，可能处于等待状态

表 4 方位词映射表

原始自然语言表达	归一化位置标签（标准 JSON 字段）	语义说明
道路中间、正中间、正前道路	center_road	行人或车辆处于车道中央位置
路边、边上、人行道	roadside	紧邻车道的道路边缘区域
斑马线、过街线、十字路口中	crosswalk/intersection_center	行人过街或车辆处于交叉口中央
靠近路口、进入路口前	intersection_approach	距交叉口较近但尚未进入的位置

1.2.3 Prompt 工程

为实现从自然语言到可执行场景描述的稳健转

换，本研究遵循“推理与编码解耦、策略可组合、输出可验证”的设计原则，构建了一套面向自动驾驶场景解析的 Prompt 工程方法。其核心由三部分组成：本体与模式定义、模块化提示组织、组合式推理—编码流程，并辅以解码约束与结果验证机制以提升可执行率与一致性，图 2 展示了 Prompt 工程的整体流程。

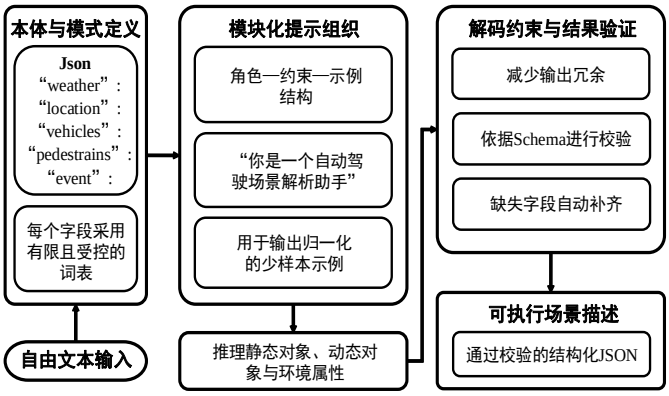

图 2 Prompt 工程流程示意图

(1) 本体与模式定义

本研究将自由文本映射为固定 JSON 架构与受控词表，包括 weather、location、vehicles、pedestrians、event 五类字段。针对各字段预先设定了有限且明确的合法取值集合，覆盖天气、地点、车辆、行人行为与位置、事故类型及其成因等，确保标注一致性，并规定必填/选填与取值约束，从而在跨场景与跨实验设定下保持语义一致性与可比性。该步骤为后续少样本示例（few-shot）学习与自动化校验提供了统一接口。

(2) 模块化提示组织

提示模板采用角色—约束—示例的三段式结构：

角色设定：明确模型为“自动驾驶场景解析助手”，限定任务边界与输出目标；

结构化输出约束：以清单形式给出字段、取值空间与命名规范，要求模型仅在受控词表中选择；

few-shot：提供覆盖典型因果链（如“雨天—急刹—追尾”）的输入、输出对，固化输出格式与关键术语的归一化表达。该模块化设计便于在不同模型与采样策略间切换，并支持快速扩展新场景。

(3) 组合式推理——编码流程

为应对自然语言描述中的缺省与歧义信息，本研究将流程划为“先推理、后编码”两阶段并显式解耦。在推理阶段，Deepseek 在 Prompt 引导下，从自由文本中梳理环境条件、交通参与者、行为过程和事件结果，补全隐含的因果关系，而不是直接生成 JSON 字段；同时，对“车开得很快”、“离路口不远”等模糊表达给出带假设的解释，结合物理和语义约束剔除明显不合理选项。在此基础上，编码阶段将这些中间语义表示映射为预定义的 JSON 架构，对于速度区间、初始间距、反应时延等文本中未给出精确数值的属性，依据先验范围和交通领域经验生成具有合理区间或安全距离约束的参数，在保留语义不确定性的同时，保证后续碰撞一致性约束和仿真执行的物理可行性。

推理阶段：首先归纳场景中的静态对象（如道路结构、标志线）、动态对象（如车辆、行人）与环境要素，识别其关键属性；对于难以直接确定的属性（如速度、初始位姿、信号相位），提出澄清性问题并给出假设；该假设可为确定值，亦可采用概率分布建模，例如在存在取值范围约束时，将速度表示为截断正态：

$$v \sim TruncNormal\left(\mu,\sigma^2;\left[v_{min},v_{max}\right]\right) \tag{1}$$

其中，v 表示某时刻车辆速度；μ 表示速度分布的均值；σ 表示速度分布的标准差；σ^2 表示方差；v_{max}，v_{min} 表示速度的上下界。

编码阶段：完成对象与属性的归一化后，生成符合预定义的 JSON 表达；必要时再将该 JSON 映射为可执行的仿真脚本。该分阶段策略一方面显式记录不确定性的来源与处理方式，另一方面降低了由语义漂移引发的编译与执行失败率。

(4) 解码约束与结果验证

为保证生成结果在结构和语法上的正确性，本研究采用低温采样和长度约束来减少冗余文本；引入 JSON 模式定义校验和词表校验器，对解码结果进行验证与自动修复，包括对超出词表的词项进行归一化处理、缺失字段补齐以及对象与事件间的一致性检查。为保证由概率属性采样得到的场景实例在语义与物理层面均可执行，本研究在解码后验证阶段引入碰撞一致性约束。设后车与前车的速度分别为 v_{rear} 与 v_{front}，$\delta>0$ 为触发追尾所需的最小相对速度差阈值。Vogel 等人[22]表明，当 TTC 低于某一阈值时，可认为车辆处于追尾高风险状态，在给定初始距离和安全时间阈值的条件下，可以得到 δ 的合理取值区间。本研究在该区间内选取符合典型城市工况的具体取值。$\tau\in(0.8,1.0)$ 为事故目标门限，表示目标场景中发生追尾的目标概率水平，其设定基于自动驾驶安全评估中对于碰撞概率和事故率而设定的风险门限[19]。本研究要求在给定初始车间距和工况条件下，后车相对前车速度差超过阈值 δ 的概率不低于事故目标门限 τ，即：

$$P\left(v_{rear}-v_{front}>\delta\right)\geq\tau \tag{2}$$

其中 $P(\square)$ 表示括号内事件发生的概率。

当式(2)不满足时，对速度分布做最小幅度的自适应修正，优先提高后车均值 μ_{rear}、降低前车均值 μ_{front} 或

适度增大标准差σ，直至满足阈值条件。同时联合碰撞时间（TTC）与制动距离（s_{brake}）约束以确保动力学可行性：

$$TTC = \frac{d_0}{\max\left\{v_{rear} - v_{front}, \delta\right\}} \tag{3}$$

$$s_{brake} = \frac{v_{rear}^2}{2a_{max}} \tag{4}$$

其中$\delta > 0$为数值稳定项，a_{max}为后车采用的最大减速带，要求$TTC \ge TTC_{min}$且$s_{brake} \le \kappa d_0$，其中TTC_{min}表示最小安全 TTC 阈值，$\kappa \in (0,1]$为几何安全系数。该约束组保证所生成样本与道路几何及初始间距d_0相容。若任一约束不满足，按优先策略（提高v_{rear}、降低v_{front}或缩小d_0）进行最小幅度参数调整并重采样，直至满足约束。

对车与人的碰撞，要求在同一时间窗口内轨迹相交且最近距离不超过$r_e + r_p$，并满足$|t_e - t_p| \le \Delta t$与合法区域约束，其中r_e与r_p分别表示车辆和行人的等效半径，t_e与t_p分别表示车辆和行人到达冲突区域最近点的时间，Δt表示两者通过同一冲突区域时允许的时间重叠窗口，用于判断是否属于同一潜在碰撞事件。

为增强极端事故的确定性，在需要时启用确定性约束条件$d_0 < (v_{r0} - v_{f0})t_r + \frac{v_{r0}^2}{2a_r} - \frac{v_{f0}^2}{2a_f}$作为补充条件，其中$d_0$表示初始间距，$v_{r0}$，$v_{f0}$表示后车和前车的初速度，$t_r$表示反应时延，$a_r$表示后车最大减速度，$a_f$表示前车最大减速度。

1.3 脚本生成器模块

脚本生成器模块是实现结构化语义到可执行仿真代码转化的关键环节，负责将前端语言理解产生的交通场景 JSON 自动映射为 CARLA 仿真环境中的可执行控制脚本。该模块由四个子模块构成：环境建模、交通参与者部署、行为控制、多视角感知采集，具备高度模块化、解耦性与可拓展性，为复杂交互场景的复现与多模态数据生成提供支撑。

1.3.1 环境建模子模块

环境建模子模块将语义解析模块输出的天气信息映射为 CARLA 仿真平台支持的环境配置参数，并据此初始化虚拟世界的气象状态。

该模块以结构化 JSON 中的 weather 字段为输入，支持将高层语义标签自动解析为低层环境变量组合。当前系统支持晴天、雨天、雪天等多种典型气象条件，每种配置涵盖多个子参数控制，如云量、雨量、湿度、风速等，确保场景呈现的细致程度与物理一致性。

为增强通用性与扩展性，系统设计预留了扩展接口以适配组合式天气模拟，例如“夜间+雾天”、“雨天+路面湿滑+大风”等多条件叠加配置，为极端场景构造提供环境多样性支撑，如下图 3 所示，展现了在 CARLA 中的四种极端恶劣天气状况。

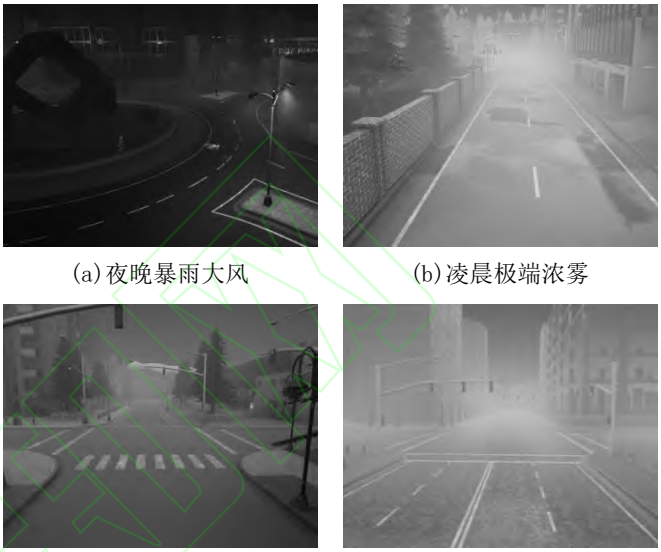

(a) 夜晚暴雨大风　(b) 凌晨极端浓雾

(c) 沙尘暴　(d) 飓风暴雨

图 3 CARLA 中恶劣环境示意图

1.3.2 交通参与者部署子模块

交通参与者部署子模块负责解析语义结构中的交通主体信息，并完成实体生成、空间部署与初始状态配置等关键任务。

该模块以结构化语义中的 vehicles 与 pedestrians 字段为输入，首先依据每类交通参与者的类型，如 car、truck、bus、motorcycle、pedestrian 等，自动匹配 CARLA 蓝图库动态生成对应实体。随后，系统调用预定义的语义位置映射函数，将自然语言中带有主观方位描述，如交叉口中心、右前方车道、路边等，转化为 CARLA 坐标系下的具体位置，确保部署位置与语义场景一致性。该模块支持多参与者并发部署与初始化姿态配置，适配追尾、碰撞、避让等多主体场景表达需求。为提升部署的灵活性与扩展性，系统支持用户对位置标签与交通参与者的自定义，具备良好的适配能力与交互场景覆盖广度。

1.3.3 行为控制子模块

行为控制子模块负责将结构化语义中的行为描述映射为交通参与者的动态动作建模，用于复现自然语言所描述的事故诱因和行为演化过程。该模块以行为字段为调用依据，将“急刹车”、“躲避行人”等高层语义动作抽象为可复用的行为模板，内部自动组合油门、转向、制动等底层控制指令，并与碰撞一致性

约束、时间到碰撞和安全距离等条件联动调度，从而在仿真环境中稳定复现具有因果关系的复杂交互场景。每类行为模板由独立的行为函数实现，显式定义实体的控制逻辑和关键参数，如目标速度、转向控制、制动力度、行为持续时长等，支持多车多行为的并发执行，同时允许在既有接口规范下灵活扩展新的动作类型，而不影响主框架运行。

为适配多车、多行人并发交互的复杂交通场景，行为控制子模块还支持对行为函数进行并行调用与调度，并根据事件发生后的车辆状态变化动态更新后续动作序列，有效支撑极端行为在虚拟环境中的复现。

1.3.4 多视角感知采集子模块

多视角感知采集子模块面向自动驾驶系统感知模型与多模态学习任务的数据需求，设计了六视角同步图像采集机制。该模块在主车实体上部署六个 RGB 相机传感器，如图 4 所示，分别位于车辆的正前方（0°）、左前方（55°）、右前方（-55°）、正后方（180°）、左后方（110°）、右后方（-110°）六个方向，实现对车辆周围环境的 360°感知覆盖。

采集系统采用 CARLA 的同步模式运行，从而保证仿真步长与图像采集在时间上精确对应。各相机以固定频率（10 Hz）输出图像帧，并依据输入的自然语言指令生成分层目录结构，从而确保数据在存储与检索过程中实现可追溯及高效的批量化管理。

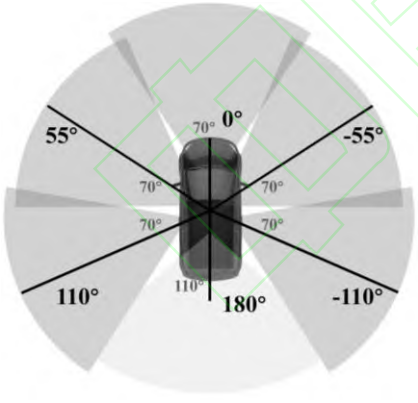

图 4 车载相机布局分布图

1.4 CARLA 仿真执行模块

CARLA 仿真执行模块负责调度前端生成的自动驾驶控制脚本，实现语义驱动场景在三维仿真环境中的高保真还原与多模态数据采集。系统首先完成仿真环境的初始化配置，包括加载目标地图、启用同步仿真模式与固定帧率 Tick 控制机制，从而确保各类感知模块、行为控制逻辑与仿真运行保持时间一致性。在执行阶段，系统自动调用脚本生成器模块输出的控制脚本，完成交通参与者部署、行为函数绑定与传感器挂载，并以固定帧数推进仿真过程。运行过程中，六视角相机以预设频率同步采集图像数据，并按自然语言输入创建结构化输出目录，便于后续检索与使用。此外，系统支持扩展采集车辆轨迹、速度曲线、碰撞记录等信息，为行为建模、风险预测及模型测试提供真实、可控、高复现性的测试数据闭环。该模块构成从语义输入到可执行仿真与数据输出的最终一环，实现端到端的自然语言驱动场景生成体系的完整闭环。

2 场景生成实验

实验通过预训练的 Deepseek 大语言模型生成脚本，随后通过 Python 3.9 API 使用 CARLA 0.9.15 执行脚本。设计的场景考虑了车辆在驾驶过程中的众多因素，如环境因素、交通参与者类型及行为动作、事件结果等；生成了车辆在驾驶过程中的各种突发极端场景，如因能见度低而误闯红灯、前方车辆急刹车导致后车撞了上去等。本研究给出了两个不同的场景示例，并详细介绍了它们的描述以及在 CARLA 环境中实现的动态场景。

2.1 场景 1：中心车辆因躲避前方车辆而突然换道

第一个场景如图 5 所示，模拟了城市道路中的典型危险情形：中心车辆因避免与前方车辆发生碰撞而实施突发换道，这张图展现了六个视角下捕捉到的场景变化，每个视角下以顺时针的顺序进行排列，展现了中心车辆紧急换道的全过程。该场景结合了真实交通环境中的不确定性与突发性，旨在考察自动驾驶系统在面对紧急驾驶行为时的感知、预测与决策能力。该场景配置如下：

(1)场景地图与道路环境。本场景基于 CARLA 仿真平台的 HD Town03 城市道路环境构建。道路为双向多车道的十字路口设计，带有清晰的车道线和交通信号灯，能够反映城市通勤场景中的复杂交互关系。

(2)天气与时间条件。天气条件设定为晴朗且光照适中的白天场景。

(3)参与者与行为动作。前方车辆：前方车辆在目标车道上以较低速度行驶，形成潜在的交通阻碍。中心车辆：中心车辆高速接近前方车辆，保持的纵向安全距离不足；中心车辆突然向左打方向，开始实施换道；中心车辆完成横向位移并并入左侧车道。

(4)事件结果。中心车辆通过左侧换道成功避免与前方车辆发生追尾碰撞。

(5)潜在风险。由于换道动作缺乏提前预警，该过程可能对左侧车道的其他潜在交通参与者造成突发风险。

该场景具有突发性与危险性的典型特征，能够有效反映复杂交通环境下的驾驶行为模式，尤其适合用

于验证自动驾驶系统在换道意图识别、轨迹预测与紧急避险等方面的性能与鲁棒性。通过该类场景的测试，可以评估自动驾驶车辆在突发危险情况下的反应能力，从而为提升系统的安全性提供有力支撑。

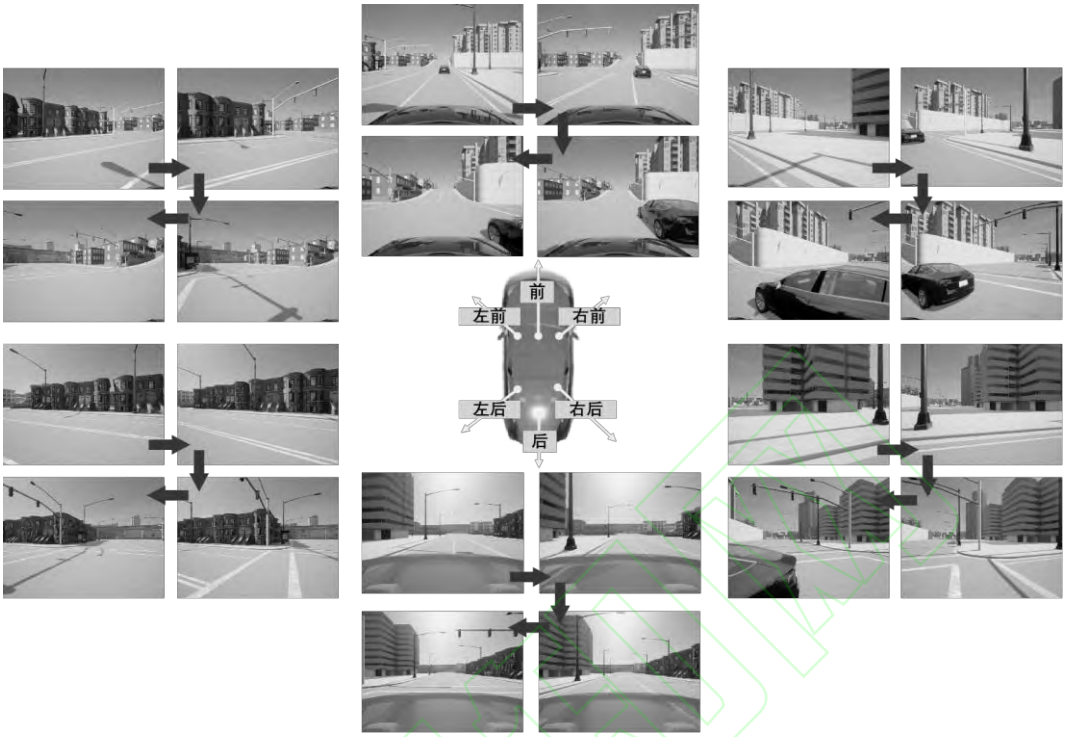

图 5 场景 1：中心车辆因躲避前方车辆而突然换道

2.2 场景 2：大雾天前方车辆为避开行人紧急制动致中心车辆追尾

第二个场景如图 6 所示，模拟了恶劣天气条件下的典型危险情形：在大雾天气中，前方车辆因突然出现的行人而采取紧急制动，导致中心车辆因能见度受限与反应时间不足而发生追尾。这张图展现了六个视角下捕捉到的场景变化，每个视角下以顺时针的顺序进行排列，完整记录了从行人入侵车道到碰撞发生的全过程。该场景体现了低能见度环境与突发事件的叠加效应，旨在考察自动驾驶系统在复杂气象条件下的感知、预测与决策能力。该场景配置如下：

(1)场景地图与道路环境。本场景基于 CARLA 仿真平台的 HD Town03 城市道路环境构建。道路为双向多车道的十字路口设计，带有清晰的车道线和交通信号灯，能够反映城市通勤场景中的复杂交互关系。

(2)天气与时间条件。天气条件设定为大雾，能见度显著下降，光照水平对应阴天的白天场景，从而增强感知难度与驾驶风险。

(3)参与者与行为动作。行人：从道路一侧突然闯入人行横道，触发危险事件。前方车辆：在察觉到行人入侵后立即采取紧急制动以避免撞击。中心车辆：紧随前车行驶，因大雾天气导致视距受限和制动反应不足，最终未能及时减速而与前车发生追尾。

(4)事件结果。前方车辆成功避免了与行人发生碰撞，但中心车辆因未能及时制动而与前车发生追尾事故。

(5)潜在风险。该场景不仅存在由行人乱穿马路带来的直接风险，还进一步体现了恶劣天气条件对感知与反应的影响。在多因素叠加下，中心车辆的追尾行为可能引发二次事故，对整体交通安全造成威胁。

该场景综合呈现了恶劣气象条件、行人突发入侵、前车紧急制动以及中心车辆追尾等多重典型风险因素，真实再现了城市道路环境中潜在的高危驾驶情境。该类场景的多维度复杂性和高度危险性，为系统性评估自动驾驶车辆在低能见度感知、行人检测、碰撞预测以及紧急避险决策等关键能力方面的性能提供了严苛且具有代表性的测试条件。

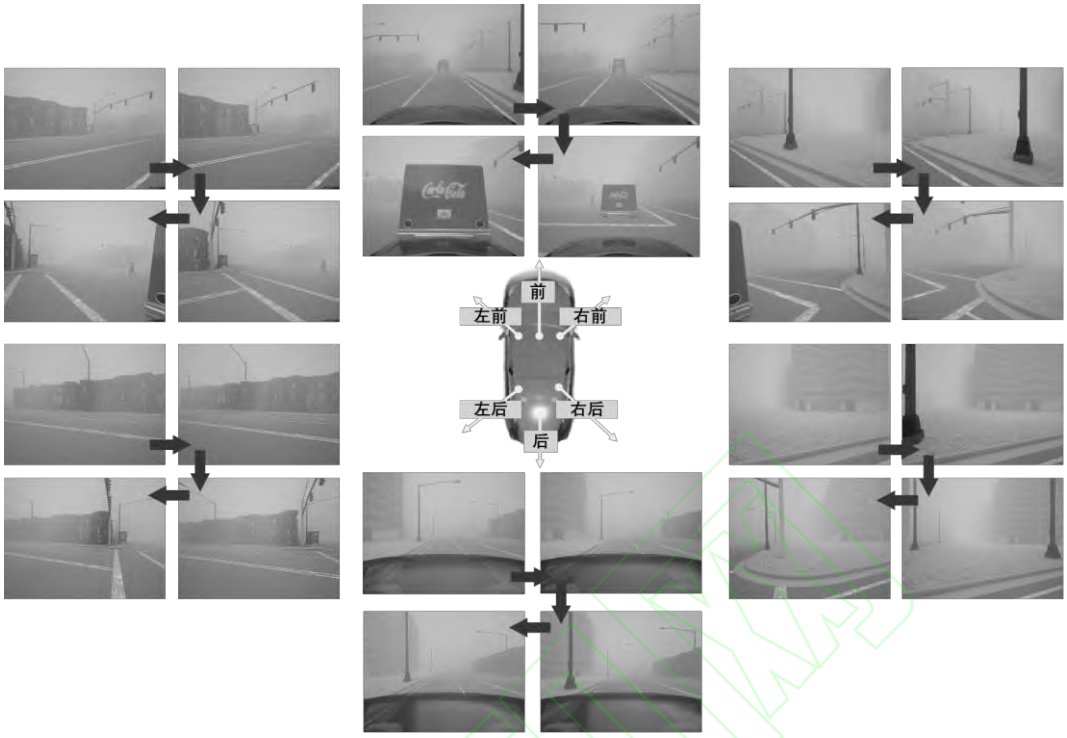

图 6 场景 2：大雾天前方车辆为避开行人紧急制动致中心车辆追尾

3 场景生成模型评估

为全面验证本研究提出的自然语言驱动场景生成方法的有效性与鲁棒性，本章从评价指标设计与消融实验分析两个方面展开系统评估。

3.1 评价指标设计

在自动驾驶测试场景生成任务中，模型的性能评价不仅依赖于语义解析的准确性，还应综合考量生成脚本的可执行性、事件逻辑的合理性以及对下游测试的支撑价值。为此，本研究从多个维度设计了一套系统化的评价指标，用于全面衡量所提出方法的有效性与鲁棒性，具体定义与计算方式如表 5 所示。

表 5 场景生成模型评价指标及计算方式

指标名称	定义与说明	计算公式
场景准确率	输入描述中的语义要素是否被正确映射为脚本参数	准确率 $=\frac{\text{正确映射的语义要素数}}{\text{语义要素总数}}\times 100\%$
逻辑一致性	场景事件顺序是否合理	逻辑一致性 $=\frac{\text{逻辑正确场景数}}{\text{总场景数}}\times 100\%$
可执行率	生成脚本能否在 CARLA 环境中直接运行	可执行率 $=\frac{\text{成功运行脚本数}}{\text{总脚本数}}\times 100\%$
行为合理性	车辆/行人行为是否符合物理常识	行为合理性 $=\frac{\text{合理行为数}}{\text{总行为数}}\times 100\%$

3.2 消融实验设计

在本研究提出的自然语言驱动场景生成方法中，整体框架由多个关键模块共同构成，不同模块分别承担语义解析、提示构造、环境配置以及行为控制等功能。为了明确各模块在系统性能中的作用，本研究首先对模型进行了功能性拆解，并结合模块特性设计了对应的消融实验。具体而言，语义解析模块通过归一化行为标签确保自然语言输入的多样表达能够统一映射为标准化语义；Prompt 构造模块通过结构化约束与链式推理提升解析稳定性与逻辑一致性；环境配置模块借助天气标签体系实现多种气象条件的可控映射；行为控制模块则依托人车行为函数库复现复杂交通交互与极端事件。本研究设计了四类消融变量以逐一验证各模块的贡献，其功能与消融设置如表 6 所示。

表 6 消融变量设置

模块	主要功能	消融变量设置
语义解析模块	将自然语言场景描述解析为结构化语义信息；保证解析结果稳定性与一致性	行为标签归一化：关闭 vs 开启（同义词标准化映射）
Prompt 构造模块	设计高质量提示以引导 LLM 输出结构化结果，提升逻辑一致性	Prompt 构造策略：朴素 Prompt vs 结构化+Json+完整示例
环境配置模块	将语义信息中的天气条件映射为仿真环境参数	环境标签：固定默认环境配置 vs 启用人工设定的天气标签映射
行为控制模块	调度车辆/行人动作逻辑，实现交互与极端事件复现	行为函数库：最小配置 vs 完整配置

3.3 消融实验结果

为验证各核心模块对整体性能的影响，该实验分别消除或简化四个模块的功能，保持其余模块不变，从而观察系统在不同设置下的性能差异。本研究基于 36 组代表性场景构建实验集，其中涵盖了多样化的道路环境、交通参与者组合以及极端事件触发情境。在完整模型和各消融配置下，分别在同一场景集合中运行实验，所有实验均采用相同的自然语言输入和仿真环境设置，不同配置之间仅在目标模块开关上存在差异。实验结果如表 7 和图 7 所示。

表 7 消融实验结果对比

模块设置	场景准确率(%)	逻辑一致性(%)	可执行率(%)	行为合理性(%)
完整模型	77.8	72.2	80.6	83.3
- 语义解析模块	22.2	38.9	30.6	44.4
- Prompt 构造模块	44.4	52.8	41.7	50.0
- 环境配置模块	52.8	69.4	58.3	75.0
- 行为控制模块	19.4	13.9	13.9	11.1

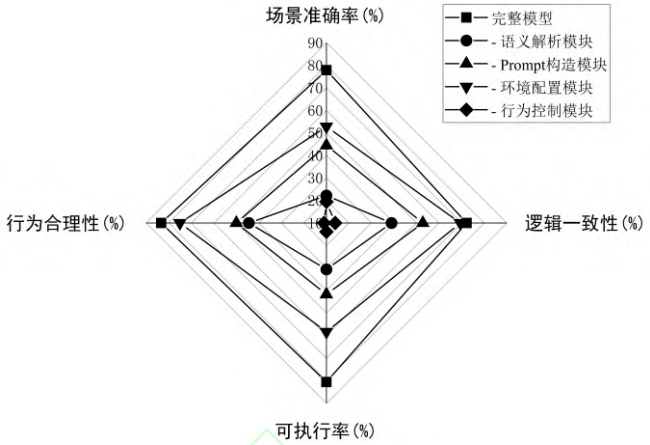

图 7 消融实验结果对比

由表 7 的实验结果可以分析得出各模块对整体性能均具有显著影响：

语义解析模块：缺失该模块后，四项指标均显著下降，尤其是场景准确率和可执行率跌至较低水平，这表明通过同义词与语义变体的标准化映射，有效增强了语义解析的一致性和脚本生成的稳定性。

Prompt 构造模块：通过结构化 JSON 模板与示例约束规范 LLM 输出，使语义解析结果能直接映射为可执行脚本。与朴素 Prompt 相比，该设计的场景准确率显著提升 33.4%，可执行性提升 38.9%，减少了语法与 API 错误，证明其在提升生成稳定性和实用性方面的重要作用。

环境配置模块：确保语义解析得到的天气标签能正确映射为 CARLA 可执行的环境参数。若缺失该模块，场景始终停留在默认天气，无法体现多样性。启用后场景准确率提升 25.0%，验证了其在增强场景多样性与逼真度方面的关键价值。

行为控制模块：缺失该模块后，所有指标几乎崩溃，验证了行为函数库在驱动车辆与行人执行复杂动作、复现极端事件中的决定性作用。

4 结 语

本研究针对现有自动驾驶测试场景生成方法存在构建效率低、难以复现极端场景以及缺乏自动化闭环验证的问题，提出了一种融合大语言模型的自然语言驱动仿真场景生成方法。该方法以自然语言场景描述为输入，通过语义解析、脚本生成、环境配置和行为控制等模块，实现了从语言输入到 CARLA 仿真平台可执行脚本的自动映射，形成完整的端到端生成与执行闭环。同时，系统集成了六视角同步感知与多模态数据采集机制，能够支持复杂交通交互、极端事件复现以及多源数据输出。

实验结果表明，所提出方法在场景准确率、逻辑

一致性、可执行率、行为合理性等多个指标上均表现出良好的性能。特别是消融实验验证了各核心模块的重要性：语义解析模块通过归一化行为标签明显提升了解析稳定性，Prompt 构造模块保证了语义到脚本的映射完整性，环境配置模块确保了天气条件的有效加载与变化，行为控制模块则通过丰富的函数库实现了复杂交互与极端事件的高保真复现。这些结果共同证明了本研究方法在生成多样化、高风险且可复现的测试场景方面的有效性和鲁棒性。

参 考 文 献

[1] Menzel T, Bagschik G, Maurer M. Scenarios for development, test and validation of automated vehicles[C]//2018 IEEE intelligent vehicles symposium (IV). IEEE, 2018: 1821-1827.

[2] Riedmaier S, Ponn T, Ludwig D, et al. Survey on scenario-based safety assessment of automated vehicles[J]. IEEE access, 2020, 8: 87456-87477.

[3] Gambi A, Nguyen V, Ahmed J, et al. Generating critical driving scenarios from accident sketches[C]//2022 IEEE International Conference On Artificial Intelligence Testing (AITest). IEEE, 2022: 95-102.

[4] Gambi A, Huynh T, Fraser G. Generating effective test cases for self-driving cars from police reports[C]//Proceedings of the 2019 27th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering. 2019: 257-267.

[5] 王淳浩，闭家铭，阮利，等. 自动驾驶安全关键场景生成技术综述[J]. Information & Control, 2024, 53(1).

[6] Sun S, Gu Z, Sun T, et al. Drivescenegen: Generating diverse and realistic driving scenarios from scratch[J]. arXiv preprint arXiv:2309.14685, 2023.

[7] Feng L, Li Q, Peng Z, et al. Trafficgen: Learning to generate diverse and realistic traffic scenarios[J]. arXiv preprint arXiv:2210.06609, 2022.

[8] Tan S, Wong K, Wang S, et al. Scenegen: Learning to generate realistic traffic scenes[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 892-901.

[9] Zhou J, Wang L, Meng Q, et al. Diffroad: Realistic and diverse road scenario generation for autonomous vehicle testing[J]. arXiv preprint arXiv:2411.09451, 2024.

[10] Li Q, Peng Z M, Feng L, et al. Scenarionet: Open-source platform for large-scale traffic scenario simulation and modeling[J]. Advances in neural information processing systems, 2023, 36: 3894-3920.

[11] Tang S, Zhang Z, Zhou J, et al. Legend: A top-down approach to scenario generation of autonomous driving systems assisted by large language models[C]//Proceedings of the 39th IEEE/ACM International Conference on Automated Software Engineering. 2024: 1497-1508.

[12] Ruan B K, Tsui H T, Li Y H, et al. Traffic scene generation from natural language description for autonomous vehicles with large language model[J]. arXiv preprint arXiv:2409.09575, 2024.

[13] Miceli-Barone A V, Lascarides A, Innes C. Dialogue-based generation of self-driving simulation scenarios using large language models[J]. arXiv preprint arXiv:2310.17372, 2023.

[14] Cai X, Bai X, Cui Z, et al. Text2scenario: Text-driven scenario generation for autonomous driving test[J]. arXiv preprint arXiv:2503.02911, 2025.

[15] Chang C, Wang S, Zhang J, et al. Llmscenario: Large language model driven scenario generation[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2024, 54(11): 6581-6594.

[16] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[17] Caesar H, Bankiti V, Lang A H, et al. nuscenes: A multimodal dataset for autonomous driving[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11621-11631.

[18] Ma J, Che X, Li Y, et al. Traffic scenarios for automated vehicle testing: A review of description languages and systems[J]. Machines, 2021, 9(12): 342.

[19] Ko W, Park S, Yun J, et al. Development of a framework for generating driving safety assessment scenarios for automated vehicles[J]. Sensors, 2022, 22(16): 6031.

[20] Sproat R, Jaitly N. RNN approaches to text normalization: A challenge[J]. arXiv preprint arXiv:1611.00068, 2016.

[21] Zhang H, Sproat R, Ng A H, et al. Neural models of text normalization for speech applications[J]. Computational Linguistics, 2019, 45(2): 293-337.

[22] Vogel K. A comparison of headway and time to collision as safety indicators[J]. Accident analysis & prevention, 2003, 35(3): 427-433.